

The LCK logo is a yellow rounded square with the letters "LCK" in black, serif font.

Modelo de Scouting LCK

Clasificación de jugadores: LCK vs. LCK Challengers League

Fase final · Machine Learning aplicado al scouting de esports

Autor: [Tu nombre] Institución: [Tu institución]

El problema de scouting

¿Se puede diferenciar estadísticamente a un jugador de LCK de uno de la academia (LCK CL), y usar eso para apoyar decisiones de promoción?

Hoy la decisión es subjetiva

ver partidas, hablar con coaches. El objetivo: sumar una señal cuantitativa y objetiva.

LCK — élite

Liga principal (Faker, Chovy, Kiin). 10 equipos, nivel mundial.

LCK CL — academia

Liga de desarrollo. Jugadores de 17–21 años que buscan ascender.

Qué esperábamos encontrar

1 **H1**

Los jugadores de LCK tienen métricas más altas de oro, farmeo y KDA.

2 **H2**

Las diferencias a los 15 minutos (oro y experiencia) son buenos predictores.

3 **H3**

La posición (rol) del jugador afecta los patrones y debe incluirse.

Dataset y variable objetivo

8,000

registros (jugador × partida)

35.6%

son de LCK (clase positiva)

1.81 : 1

desbalance (CL : LCK)

Variable objetivo: is_lck (1 = LCK, 0 = LCK CL)

Fuente: inspirada en Oracle's Elixir (LCK/LCK CL 2022-2024).

Datos simulados y reproducibles (semilla 42): el avance ya usaba datos simulados; se conservan para mantener la comparabilidad. Con datos reales los resultados pueden variar.

Sin fuga de información


Variables excluidas (fuga)

league — es el origen de la etiqueta

gameid, playerid, teamid — identificadores

Se eliminan ANTES de particionar. Todo ajuste (imputación, escalado, codificación) se hace solo con train, dentro del pipeline.

Partición 70 / 15 / 15



Estratificada · semilla 42 · el test se usa UNA sola vez, al final.

Pipeline e ingeniería de características

Pipeline consolidado

Numéricas: imputación (mediana) + estandarización.

Categorica (posición): moda + OneHot con manejo de categorías desconocidas.

Todo dentro de un Pipeline: mismas reglas en train, test e inferencia; serializable.

4 características nuevas

oro_por_cs15

oro por unidad de farreo temprano

dominancia15

ventaja total de oro + exp a los 15'

participacion15

involucramiento temprano (kills+asist.)

impacto_dano

daño ponderado por cuota de equipo

Se calculan por partida → riesgo de fuga nulo.

Validación cruzada repetida

RepeatedStratifiedKFold

5 particiones × 3 repeticiones = 15 evaluaciones


Semilla 42 · Métrica principal: F1 · Secundarias: ROC-AUC, precision, recall.

El test NUNCA se toca durante la selección.

¿Por qué repetida?

- Promedia sobre 15 particiones distintas.
Reduce la varianza de la estimación.
No depende de una sola división afortunada.
Da una comparación más justa entre modelos.

Comparación entre familias de modelos



Lectura

Los modelos lineales encabezan.

La señal en estos datos es mayormente lineal, así que un modelo simple compite con los complejos.

Dummy (referencia) = 0.00 en F1.

Selección de variables y ajuste



Selección de características

SelectFromModel: de 27 → 14 variables sin pérdida relevante de F1 (0.664 vs 0.663). Más simple e interpretable.



Ajuste de hiperparámetros

RandomizedSearch (RF) y GridSearch (SVM), solo con train. Mejor SVM lineal $C=0.1 \rightarrow F1\ 0.692$.



SMOTE vs. class_weight

SMOTE dio 0.673 vs 0.664: mejora marginal. Se mantiene class_weight por simplicidad operativa.

Finalistas y modelo elegido

Matriz de decisión (pesos = 100%)

Criterio	Peso	Reg. Log.	SVM lin.
Recall	25	1	5
Precision	15	5	1
F1 / ROC-AUC	40	5	1
Estabilidad	10	5	1
Interpret./Costo	10	5	3.5
PONDERADO	100	4.0	2.25

GANADOR

Regresión Logística

Iguala al SVM en desempeño, pero es mucho más interpretable y barata de operar. No se elige por la métrica más alta, sino por el mejor equilibrio.

Prueba: una sola vez

0.738

Recall

0.832


ROC-AUC

0.680

F1-score

0.631

Precision




¿Confirma la validación?

Sí. F1 pasó de ~0.692 en validación a 0.680 en prueba: pérdida pequeña y esperable.

Sin señales de sobreajuste. El modelo generaliza y la selección no cambia.

Elegir el punto de corte



Umbral = 0.40


Criterio: máximo F1 con recall ≥ 0.80 , elegido en validación.

Prioriza no perder talento (recall) sin desplomar la precisión.

No debe adoptarse sin revisión

organizacional: el punto exacto depende del costo real de cada error.

Qué mira el modelo




Factores dominantes

- 1 earnedgpm — oro por minuto
- 2 cspm — farreo por minuto
- 3 golddiffat15 — ventaja de oro
- 4 xpdiffat15 — ventaja de exp.


Coincide con las hipótesis. La importancia NO implica causalidad: son asociaciones, no relaciones causa-efecto.

Análisis de sesgos

Recall por posición



Recall por nivel de gasto (oro/min)



El recall es más bajo en roles de menor oro (soportes, mid) y en jugadores de bajo gasto. No es discriminación por sí sola: refleja que 'oro/min' es el predictor dominante y la calidad de los datos. Mitigación: métricas por subgrupo y posible umbral por rol.

Riesgos y condiciones de uso

Uso automático

Ninguna decisión sobre un jugador se automatiza. Siempre hay revisión humana.

Falsos negativos

Perder un talento. Se mitiga priorizando recall y con revisión de scouting.

Drift (meta/parche)

El juego cambia; el modelo debe monitorearse y reentrenarse.

Datos y sesgo

Datos simulados y desempeño desigual por rol: validar antes de un uso real.

Conclusión

Una herramienta de apoyo, prudente y defendible

- 1 Funciona** Distingue ambas ligas (AUC 0.83, recall 0.74) y supera con holgura al baseline.
- 2 Es transparente** Modelo lineal interpretable; sabemos por qué predice lo que predice.
- 3 Es reproducible** Semilla fija, reproducción del avance bit a bit, artefacto verificado con hash.
- 4 Es prudente** Umbral justificado, análisis de sesgos y revisión humana obligatoria.

Recomendación: usarlo en una prueba controlada, acompañando al scouting, con monitoreo y revisión periódica.